

Аналитический отчет по курсовой работе

Студент: Чистов Александр, 371215(?)

Задача	4
Данные	5
EDA	6
Исходные данные (Данные_для_курсовой_Классическое_MO.xlsx)	6
Обработанные данные (df)	6
Итоговый вывод по результатам EDA	6
1. Очистка и предобработка:	6
2. Анализ целевых переменных:	7
3. Корреляционный анализ:	7
4. Готовность к обучению:	7
Итог	7
Задачи регрессии	8
IC50	8
Тут пришлось немного порассуждать на вопрос допустимости включения CC50 в список признаков для обучения данной модели:	8
1. Биологический смысл связи	8
2. IC50, CC50, SI — это результаты биологических экспериментов	8
Было обучено 2 модели:	8
Прирост	9
Вывод	9
Интерпретация результатов моделей	9
Дополнительно:	9
Итоговые выводы	10
CC50	10
Интерпретация результатов моделей	10
Дополнительно:	10
Итоговые выводы	10
SI	11
Интерпретация результатов моделей	11
Вывод:	11
Задачи классификации	12
IC50 > медианы	12
ROC-AUC	12
RandomForest	12
RandomForest показал хорошие результаты ROC-AUC(0.81) и лидирует по метрикам Accuracy(0.73) и Recall(0.74), что важно для минимизации ложноотрицательных срабатываний.	12
CC50 > медианы	12
ROC-AUC	12
RandomForest	12
RandomForest показал лучшие результаты всех метрик, что важно, так	

как определение риска - один из самых важных критериев	12
SI > медианы	12
ROC-AUC	12
XGBoost	12
XGB показал лучшие результаты всех метрик, что важно, так как определение риска - один из самых важных критериев	13
SI > 8	13
Важно не пропустить перспективных соединений - попробовал сместить порог классификации для увеличения Recall	13
Recall	13
XGBoost	13
XGBoost показал лучшие результаты всех метрик	13
Итоговый вывод	14
Краткие выводы по моделям	14
Регрессия	14
Классификация	14
Практические выводы для подбора параметров препаратов	15

Задача

На основании предоставленных данных от химиков необходимо построить прогноз, позволяющий подобрать наиболее эффективное сочетание параметров для создания лекарственных препаратов.

Для этого требуется:

- ❖ Проанализировать текущие параметры с использованием различных методов.
- ❖ Научиться предсказывать их эффективность.

Как и в любой задаче машинного обучения, здесь нет однозначного ответа на вопрос, какая модель обеспечит наилучший результат. Поэтому необходимо протестировать различные подходы, проанализировать возможные результаты, сравнить качество построенных моделей и сделать обоснованные выводы.

- ❖ Нужно создать несколько максимально эффективных моделей для решения следующих задач:
 - ❖ Регрессия для IC50
 - ❖ Регрессия для CC50
 - ❖ Регрессия для SI
 - ❖ Классификация: превышает ли значение IC50 медианное значение выборки
 - ❖ Классификация: превышает ли значение CC50 медианное значение выборки
 - ❖ Классификация: превышает ли значение SI медианное значение выборки
 - ❖ Классификация: превышает ли значение SI значение 8

Данные

Химики были предоставлены конфиденциальные данные о 1000 химических соединений с указанием их эффективности против вируса гриппа.

Параметры, характеризующие эффективность, обозначаются как IC50, CC50 и SI.

Целевыми переменными являются:

- ❖ IC50 - используется для определения минимальной ингибирующей концентрации для подавления 50% возбудителя
- ❖ CC50 - цитотоксическая концентрация экстрактов, вызывающая гибель 50% жизнеспособных клеток в организме хозяина
- ❖ SI - отношение CC50 к IC50 - терапевтический индекс

EDA

Исходные данные (Данные_для_курсовой_Классическое_MO.xlsx)

- ❖ 1001 наблюдение
- ❖ 214 столбцов (1 вместо индекса)
- ❖ 18 константных столбца
- ❖ 12 столбцов с 3 пропусками в каждом
- ❖ Все признаки числовые
- ❖ Таргетные признаки показывают выраженную правостороннюю асимметрию из-за выбросов
 - IC50 = 14, 2%
 - CC50 = 3, 6%
 - SI = 12, 4%
- ❖ Признаки очень отличаются по масштабу

Обработанные данные (df)

- ❖ 969 наблюдений
- ❖ 158 столбцов
- ❖ Пропуски обработаны - заполнены медианой, чтобы сохранить информацию о соединениях
- ❖ Константные столбцы удалены
- ❖ Удалено 40 признаков с сильной корреляцией
- ❖ Добавлены логарифмированные версии таргетных признаков для уменьшения асимметрии распределений и снижения влияния экстремальных значений
 - IC50_log
 - CC50_log
 - SI_log

Итоговый вывод по результатам EDA

В ходе разведочного анализа данных (EDA) были выполнены следующие ключевые этапы:

1. Очистка и предобработка:

- ❖ Удалены дубликаты и строки с пропущенными значениями
- ❖ Исключены 18 константных признаков, не несущих полезной информации для моделей

2. Анализ целевых переменных:

- ❖ Выявлена сильная правосторонняя асимметрия в показателях IC50, CC50 и SI. Средние значения значительно превышают медианы из-за наличия «длинных хвостов»
- ❖ Зафиксировано значительное количество статистических выбросов
- ❖ Применено логарифмическое преобразование, которое успешно нормализовало распределения таргетов и снизило влияние экстремальных значений

3. Корреляционный анализ:

- ❖ Обнаружена умеренная связь между активностью (IC50) и токсичностью (CC50) ($\text{corr} \approx 0.52$)
- ❖ Было удалено 40 сильно коррелирующих признаков

4. Готовность к обучению:

- ❖ Сформированы два набора целевых переменных: исходные и логарифмированные.
- ❖ Данные полностью подготовлены для обучения

Итог

- ❖ Выраженная асимметрия и наличие выбросов могут негативно влиять на качество регрессионных моделей
- ❖ Имеет смысл тестировать разные модели, выбраны:

➤ LinearRegression, RandomForest, XGB

Задача	Основная метрика
Регрессия IC50	R^2
Регрессия CC50	R^2
Регрессия SI	R^2
IC50 > медианы	ROC-AUC
CC50 > медианы	ROC-AUC
SI > медианы	ROC-AUC
SI > 8	Recall

Задачи регрессии

IC50

Тут пришлось немного порассуждать на вопрос допустимости включения CC50 в список признаков для обучения данной модели:

1. Биологический смысл связи

- ❖ IC50 измеряет ингибирование целевого процесса
- ❖ CC50 измеряет общую токсичность для клетки

Формально:

- ❖ ингибирование $\neq$ обязательно гибель клетки
- ❖ цитотоксичность = более тяжелый эффект

Поэтому верно:

- ❖ сильная цитотоксичность часто сопровождается низким IC50
- ❖ но низкий IC50 не обязан приводить к цитотоксичности

2. IC50, CC50, SI — это результаты биологических экспериментов

- ❖ дескрипторы молекулы обычно доступны до экспериментов
- ❖ если оставить CC50, модель будет использовать информацию, которую в реальном - сценарии предсказания новой молекулы ещё нельзя знать

Было обучено 2 модели:

- ❖ С использованием CC50 в числе других признаков
- ❖ С исключением CC50 из признаков

Feature Set	Model	RMSE	MAE	R ²
No_CC50	XGBoost	1.350560	1.061347	0.505637
No_CC50	RandomForest	1.352389	1.084318	0.504297
No_CC50	LinearRegression	1.608022	1.321993	0.299188
With_CC50	XGBoost	1.167161	0.901458	0.630785
With_CC50	RandomForest	1.194530	0.920681	0.613267
With_CC50	LinearRegression	1.417721	1.193838	0.455247

Прирост

$$\diamond 0.63 - 0.51 = 0.12$$

То есть модель объясняет дополнительно около 12% дисперсии.

Это говорит о том, что:

- CC50 является очень информативным предиктором для IC50
- Модель активно использует эту информацию

Если цель:

- По дескрипторам новой молекулы предсказать IC50 - то CC50 удаляем, так как для новой молекулы CC50 ещё неизвестен.

Если цель:

- Предсказать IC50, имея результаты других экспериментов - то CC50 оставляем.

Тогда $R^2 = 0.63$ — честный результат.

Вывод

Использование CC50 повышает качество прогноза IC50 с $R^2=0.51$ до $R^2=0.63$, что указывает на существенную взаимосвязь между показателями. Однако в итоговой модели признак CC50 был исключен, поскольку он представляет собой результат отдельного биологического эксперимента и не доступен в типовом сценарии прогнозирования активности новых соединений.

Интерпретация результатов моделей

1. Наилучшее качество предсказания стабильно демонстрирует XGBoost, что указывает на наличие нелинейных зависимостей между дескрипторами и IC50.
2. RandomForest показывает сопоставимое качество, но немного уступает по объясняющей способности и стабильности.
3. LinearRegression существенно проигрывает, что подтверждает нелинейный характер задачи.

Дополнительно:

- Переход к логарифмированному таргету уменьшает влияние выбросов и стабилизирует ошибку;

- Улучшение R^2 при использовании CC50 подтверждает наличие сильной корреляции между токсичностью и ингибиторной активностью.

Итоговые выводы

1. Лучший результат достигнут моделью XGBoost с логарифмированием IC50 с $R^2 \approx 0.51$ без использования CC50.
 2. Добавление CC50 увеличивает качество до $R^2 \approx 0.63$, что подтверждает сильную связь между цитотоксичностью и ингибиторной активностью.
 3. Однако использование CC50 ограничено сценарием применения и может приводить к утечке данных при прогнозировании новых молекул.
 4. Таким образом, итоговая модель без CC50 является более корректной с точки зрения практического применения, несмотря на более низкий R^2 .
-

CC50

CC50_log демонстрирует искаженное в сторону экстремальных значений выбросов распределение, так что был использован исходный таргет CC50

Интерпретация результатов моделей

- ❖ Наилучшее качество предсказания стабильно демонстрирует RandomForest
- ❖ XGBoost показывает почти сопоставимое качество
- ❖ LinearRegression существенно проигрывает, что подтверждает нелинейный характер задачи

Дополнительно:

- ❖ Переход к логарифмированному таргету ухудшил бы качество, поэтому использовался исходный CC50

Итоговые выводы

Лучший результат достигнут моделью RandomForest на исходном CC50 с $R^2 \approx 0.54$

SI

Интерпретация результатов моделей

- SI после логарифмирования (SI_log) имеет более стабильное распределение, немного улучшая качество модели
- Лучший результат даёт RandomForest ($R^2 \approx 0.23$), при этом остальные модели показывают ещё более низкие значения
- Слабое качество объясняется природой SI как производной метрики (CC50/IC50), а также сильным искажением распределения

Вывод:

SI плохо предсказывается по имеющимся признакам. Использовать его в виде непрерывной целевой переменной нецелесообразно, но он может быть вспомогательным индикатором

Задачи классификации

IC50 > медианы

Model	ROC-AUC	F1	Accuracy	Precision	Recall
XGBoost	0.82	0.72	0.72	0.71	0.73
RandomForest	0.81	0.73	0.73	0.72	0.74
LogReg	0.77	0.71	0.71	0.72	0.70

RandomForest показал хорошие результаты ROC-AUC(0.81) и лидирует по метрикам Accuracy(0.73) и Recall(0.74), что важно для минимизации ложноотрицательных срабатываний.

CC50 > медианы

Model	ROC-AUC	F1	Accuracy	Precision	Recall
RandomForest	0.84	0.75	0.75	0.76	0.73
XGBoost	0.81	0.70	0.70	0.69	0.70
LogReg	0.78	0.72	0.71	0.69	0.75

RandomForest показал лучшие результаты всех метрик, что важно, так как определение риска - один из самых важных критериев

SI > медианы

Model	ROC-AUC	F1	Accuracy	Precision	Recall
XGBoost	0.72	0.62	0.66	0.71	0.56
RandomForest	0.69	0.62	0.65	0.68	0.57
LogReg	0.65	0.60	0.61	0.62	0.58

XGB показал лучшие результаты всех метрик, что важно, так как определение риска - один из самых важных критериев

SI > 8

Важно не пропустить перспективных соединений - попробовал сместить порог классификации для увеличения Recall

Model	Recall	Precision	F1	ROC-AUC	Accuracy	Threshold
XGBoost	0.74	0.55	0.63	0.77	0.69	0.45
LogReg	0.65	0.45	0.54	0.67	0.60	0.45
RandomForest	0.64	0.58	0.61	0.76	0.71	0.45

XGBoost показал лучшие результаты всех метрик

ИТОГОВЫЙ ВЫВОД

Краткие выводы по моделям

Регрессия

Цель	Лучшая модель	R^2	Комментарий
IC50	XGBoost	0.51	Без CC50 (честный прогноз для новых молекул)
CC50	RandomForest	0.54	Исходный таргет (не логарифмировал)
SI	RandomForest	~0.23	Очень плохо, непрерывный прогноз ненадежен

Главное: IC50 и CC50 предсказываются приемлемо. SI предсказывать в виде числа бессмысленно.

Классификация

Задача	Лучшая модель	ROC-AUC	Ключевая метрика
IC50 > медианы	RandomForest	0.81	Recall 0.74
CC50 > медианы	RandomForest	0.84	Все метрики лучшие
SI > медианы	RandomForest	0.69	Приемлемо, но хуже
SI > 8	XGBoost	0.77	Recall 0.74 (важно не пропустить кандидатов)

Практические выводы для подбора параметров препаратов

1. IC50 и CC50 можно предсказывать — модели работают стабильно. Используйте регрессию для ранжирования кандидатов, классификацию — для грубого отбора.
2. SI в непрерывном виде предсказывать бесполезно ($R^2 \sim 0.23$). Вместо этого:
 - ❖ Нужно поэкспериментировать с порогами классификации SI > 8 для максимизации Recall/F1
3. XGBoost — самый универсальный алгоритм для этих задач. Он хорошо справляется с нелинейными зависимостями и стабилен.

Итог

- ❖ Можно доверять: предсказания IC50 и CC50 ($R^2 \sim 0.5$), но стоит более внимательно подойти к вопросу предобработки и подготовки признаков
- ❖ Можно использовать как ориентир: классификация SI (> медианы или > 8)
- ❖ Нельзя использовать: регрессия SI (числовой прогноз)